UNIDAD 1 — INTRODUCCIÓN A LA INTELIGENCIA ARTIFICIAL

Material complementario del curso que compila los conceptos, línea de tiempo y áreas de aplicación de la inteligencia artificial, con el contenido en texto plano para facilitar su consulta y referencia.

1. ¿Qué es la Inteligencia Artificial?

La Inteligencia Artificial (IA) es una rama de las ciencias de la computación que se dedica al diseño de sistemas capaces de ejecutar tareas que, cuando son realizadas por humanos, requieren inteligencia: percepción, razonamiento, aprendizaje, toma de decisiones y uso del lenguaje. Es un campo de estudio multidisciplinario que combina aportes de las matemáticas, la lógica, la neurociencia, la psicología cognitiva, la lingüística y la ingeniería.

La IA abarca desde técnicas simbólicas (reglas, lógica) hasta técnicas conexionistas (redes neuronales), pasando por sistemas basados en conocimiento, agentes inteligentes y modelos generativos modernos.

2. Historia de la Inteligencia Artificial (línea de tiempo)

Los primeros pasos y la teoría de la IA (1943 – 1957)

- **1943 — Modelo de Neuronas:** McCulloch y Pitts desarrollaron el primer modelo matemático de neuronas artificiales que sentó las bases teóricas para el desarrollo de la IA, las redes neuronales y la computación neuronal. Introdujo la idea de que las redes neuronales podrían simular funciones cerebrales.
- **1950 — Test de Turing:** Alan Turing publicó "Computing Machinery and Intelligence" y propuso el Test de Turing para evaluar la inteligencia de una máquina. Estableció un estándar para medir la inteligencia artificial con preguntas filosóficas sobre la capacidad de las máquinas para pensar. Inspiró a científicos en la creación de máquinas inteligentes.
- **1956 — Conferencia de Dartmouth:** John McCarthy, Marvin Minsky y otros acuñaron el término "Inteligencia Artificial" en la Conferencia de Dartmouth. Marcó el nacimiento formal de la IA como un campo de estudio y la consolidó como una disciplina científica, atrajo financiamiento e interés académico.
- **1957 — Perceptrón:** Frank Rosenblatt desarrolló el Perceptrón, el primer modelo de red neuronal implementado en hardware. Fue uno de los primeros intentos de simular redes neuronales artificiales. Sentó bases para el desarrollo del aprendizaje profundo (Deep Learning).

Nacimiento de la Inteligencia Artificial (1958 – 1969)

- **1958 — LISP:** John McCarthy desarrolló LISP, el primer lenguaje de programación para IA. Facilitó la implementación de algoritmos de IA y permitió el desarrollo de sistemas de IA más complejos.
- **1959 — Machine Learning:** Arthur Samuel introdujo este término, al desarrollar un programa que aprendía a jugar damas. Mostró que las máquinas podían aprender de la experiencia y sentó las bases para el aprendizaje automático moderno.
- **1966 — ELIZA:** Joseph Weizenbaum creó ELIZA, el primer chatbot, que simulaba una conversación con un psicoterapeuta. Demostró que las máquinas podían interactuar de manera similar a los humanos e inspiró el desarrollo de sistemas de procesamiento del lenguaje natural (NLP).

- **1969 — Stanford Cart:** El Stanford Cart se convirtió en uno de los primeros robots móviles capaces de navegar de forma autónoma. Mostró que la IA podía integrarse en sistemas físicos. Pionero en robótica autónoma y planificación de tareas.

Auge de los Sistemas Expertos y Redes Neuronales (1980 – 1997)

- **1980 — Sistemas Expertos:** Se popularizaron sistemas expertos como XCON, que ayudaba en la configuración de computadoras. Demostró que la IA podía aplicarse en áreas específicas con resultados útiles. Popularizó el uso de reglas lógicas y bases de conocimiento en la IA.
- **1986 — Retropropagación:** Se redescubrió la técnica de retropropagación, mejorando el entrenamiento de redes neuronales. Permitió entrenar redes neuronales más profundas y complejas. Sentó las bases para el aprendizaje profundo moderno.
- **1997 — Deep Blue:** Deep Blue de IBM derrotó al campeón mundial de ajedrez Garry Kasparov. Mostró que la IA podía superar a los humanos en tareas complejas. Estimuló el interés en la IA y su aplicación en juegos y estrategias.

Expansión del Machine Learning y Big Data (2005 – 2016)

- **2005 — DARPA Grand Challenge:** Stanley, un vehículo autónomo de Stanford, ganó el DARPA Grand Challenge. Demostró la viabilidad de los vehículos autónomos en entornos complejos. Aceleró la investigación en vehículos autónomos.
- **2006 — Deep Learning:** Geoffrey Hinton introdujo el término "Deep Learning". Revolucionó el reconocimiento de imágenes y otras tareas de IA. Sentó las bases de la era moderna del aprendizaje profundo.
- **2011 — Watson en Jeopardy!:** IBM Watson ganó el concurso de preguntas y respuestas Jeopardy!. Demostró habilidades avanzadas en procesamiento del lenguaje natural. Abrió nuevas posibilidades para la IA en medicina, derecho y servicio al cliente.
- **2016 — AlphaGo:** AlphaGo de DeepMind derrotó al campeón mundial de Go, Lee Sedol. Mostró que la IA podía manejar tareas complejas de extrema complejidad. Popularizó el uso del aprendizaje por refuerzo profundo.

IA en la Vida Cotidiana (2020 – 2023)

- **2020 — GPT-3:** OpenAI lanzó GPT-3, un modelo de lenguaje con 175 mil millones de parámetros. Revolucionó la generación de texto y el procesamiento del lenguaje natural. Abrió nuevas posibilidades con aplicaciones comerciales y creativas.
- **2022 — ChatGPT:** OpenAI lanzó ChatGPT, popularizando la IA conversacional. Demostró la capacidad de la IA para interactuar de manera natural con los usuarios. Aceleró la adopción de la IA en aplicaciones cotidianas.
- **2023 — GPT-4:** Se desarrolló GPT-4, con mejoras en comprensión de lenguaje y generación de texto. Mostró avances significativos en la capacidad de la IA para entender y generar texto. Consolidó el uso de modelos de lenguaje de gran escala en diversos campos.

3. Áreas de la IA y su campo de aplicación

La Inteligencia Artificial no es un área única, sino un conjunto de disciplinas interrelacionadas. Las principales áreas de la IA son:

- **Visión computacional:** permite a las máquinas interpretar y comprender el mundo visual, procesando imágenes y videos para extraer información útil (reconocimiento facial, detección de objetos, análisis médico de imágenes).
- **Procesamiento de Lenguaje Natural (PLN o NLP):** permite a las computadoras entender, interpretar y generar lenguaje humano (traducción automática, chatbots, análisis de sentimientos, asistentes virtuales).
- **Aprendizaje automático (Machine Learning):** crea sistemas que aprenden de datos sin ser programados explícitamente para cada tarea. Es el motor de la mayoría de aplicaciones modernas de IA.
- **Razonamiento automático:** estudia cómo los sistemas pueden hacer inferencias lógicas, resolver problemas y tomar decisiones a partir de información conocida.
- **Representación del conocimiento:** estudia cómo codificar la información del mundo en estructuras que las máquinas puedan utilizar para razonar (ontologías, grafos de conocimiento, lógica).
- **Robótica:** integra la IA con sistemas físicos para crear máquinas que perciben su entorno, planifican acciones y las ejecutan (robots industriales, drones autónomos, vehículos autónomos).

4. Aprendizaje automático (Machine Learning)

Machine Learning o aprendizaje automático se divide en distintos tipos de algoritmos, entre ellos los algoritmos de agrupación. Esta disciplina, enmarcada en la inteligencia artificial, crea distintos sistemas que permiten a las máquinas aprender de forma automática. En este sentido, consigue que los ordenadores lleven a cabo tareas de forma independiente.

Dentro del aprendizaje automático encontramos tres grupos principales de algoritmos:

4.1 Aprendizaje supervisado

El modelo aprende con datos etiquetados (entrada → salida conocida). Las principales tareas son la Clasificación y la Regresión. Ejemplo: diferenciar entre fotos de gatos y perros a partir de ejemplos previamente etiquetados.

4.2 Aprendizaje no supervisado

El modelo encuentra patrones sin etiquetas. Las principales tareas son el Clustering (agrupación) y la Reducción de dimensionalidad. Ejemplo: agrupar automáticamente imágenes de mascotas sin saber de antemano qué son.

4.3 Aprendizaje por refuerzo

El modelo aprende mediante prueba y error con recompensas. Ejemplo: un robot que aprende a moverse sin chocar, obteniendo premios cuando lo hace bien.

A su vez, estos 3 tipos de algoritmos se dividen en distintos tipos, entre los que encontramos:

- Algoritmos de regresión
- Algoritmos bayesianos

- Algoritmos de agrupación (clustering)
- Algoritmos de árbol de decisión
- Algoritmos de reducción de dimensión
- Algoritmos Deep Learning (aprendizaje profundo)
- Otros algoritmos especializados

5. Algoritmos de agrupación (Clustering)

¿Qué es un algoritmo de agrupación?

Dentro de los algoritmos de aprendizaje no supervisado, nos encontramos con los algoritmos de agrupación. Se trata de una técnica común en el análisis de datos estadísticos y que se utiliza a menudo en diversos campos.

Su utilidad es, principalmente, categorizar datos que no hayan sido previamente etiquetados. Es decir, que no tengan ni categorías ni grupos definidos.

El funcionamiento de los algoritmos de agrupación se basa en la búsqueda de grupos dentro de los datos, con un número de grupos que se representa a través de la letra K. Tras esto, procede a asignar cada punto de datos a uno de los K grupos, dependiendo de las características que se le hayan proporcionado.

Métodos de agrupamiento

Un método de agrupamiento es un algoritmo de aprendizaje automático no supervisado, en el que se identifican patrones dentro de un conjunto de datos y el método genera automáticamente subgrupos de tipos similares de variables de entrada, también conocidos como clústeres.

Los algoritmos de agrupamiento generalmente operan con el supuesto de que existe un patrón subyacente en el conjunto de datos de entrada. Como resultado, sus subgrupos generados deben ser validados estadística y científicamente.

Dos de los algoritmos de agrupamiento más comunes para el procesamiento de nubes de puntos son el agrupamiento jerárquico y los algoritmos k-means.

Características de los algoritmos de agrupación

- Los datos que utilizan no tienen ninguna etiqueta previa
- El algoritmo tiene la capacidad de encontrar todos los datos sin supervisión
- Se trata de un algoritmo esencial para que los científicos de datos descubran agrupaciones

Tipos de algoritmos de agrupación

A su vez, los algoritmos de agrupación se pueden dividir en distintos tipos de algoritmo, con la capacidad de manejar todo tipo de datos no etiquetados:

- **Basados en la densidad:** los datos se agrupan según las áreas de altas concentraciones de datos que se rodean de áreas bajas de concentración de puntos de datos. A estos lugares los llama grupos.

- **Algoritmos de distribución:** se basa en la distribución y funciona detectando un punto central de datos que, a medida que aumenta la distancia a este desde el centro, la posibilidad de que se haga parte del grupo, decrece.
- **Algoritmos basados en centroides:** es el más común, rápido y eficiente. Su función es separar puntos de datos, asignando cada uno de ellos a la distancia al cuadrado del centroide.
- **Basados en jerarquías:** su utilidad está, principalmente, destinada a los datos jerárquicos. Construye un árbol de grupos para que todo esté organizado de arriba hacia abajo.

Cluster K-Means: el algoritmo de agrupación más popular

Se trata de un algoritmo perteneciente al grupo de algoritmos basados en centroides y es el algoritmo de aprendizaje no supervisado más simple, pero también el más veloz.

Su función es minimizar la variedad de puntos dentro de un grupo y se usa, preferiblemente, en conjuntos de datos más pequeños.

¿Cuándo se utilizan los algoritmos de agrupación?

Existen distintas situaciones reales en las que se usan los algoritmos de agrupación. Algunas de ellas son:

- Ventas y marketing (segmentación de clientes)
- Identificación de criminales (análisis de patrones delictivos)
- Detección de noticias falsas
- Filtros de spam en correo electrónico
- Análisis de redes sociales (comunidades)
- Diagnóstico médico (agrupación de pacientes por síntomas)
- Recomendación de productos (clientes con gustos similares)

6. Definición formal de agrupamiento

El agrupamiento (clustering) es una técnica de aprendizaje no supervisado cuyo objetivo es particionar un conjunto de observaciones en grupos o clusters, de manera que los elementos pertenecientes a un mismo grupo presenten una mayor similitud entre sí que respecto de los elementos de otros grupos.

Formalmente, dado un conjunto de datos $X = \{x1, x2, ..., xn\}$, donde cada observación xi está representada mediante un conjunto de características $(xi1, xi2, ..., xip)$, el objetivo es encontrar una partición $C = \{C1, C2, ..., Ck\}$ que maximice la similitud intra-cluster y minimice la similitud inter-cluster.

A diferencia del aprendizaje supervisado, no se dispone de una variable objetivo previamente etiquetada.

7. Medidas de similitud y distancia

Los algoritmos de agrupamiento requieren una función que permita determinar qué tan cercanos o similares son dos objetos.

Una de las más utilizadas es la distancia euclidiana, definida como la raíz cuadrada de la suma de las diferencias al cuadrado entre las coordenadas de los puntos. Es decir: d(x, y) = raíz cuadrada de la sumatoria desde j=1 hasta p de (xj - yj) al cuadrado.

También pueden utilizarse otras medidas:

- Distancia Manhattan: suma de las diferencias absolutas
- Distancia Minkowski: generalización de la distancia euclidiana
- Distancia de Mahalanobis: considera la correlación entre variables
- Similitud coseno: mide el ángulo entre dos vectores
- Distancia de Jaccard: para conjuntos de datos categóricos

La elección de la métrica depende de la naturaleza de los datos. Por ejemplo, en documentos representados mediante vectores TF-IDF suele ser más apropiada la similitud coseno que la distancia euclidiana.