UNIDAD 3 — PROCESAMIENTO DEL LENGUAJE NATURAL (PLN)

Material complementario del curso de Inteligencia Artificial. El objetivo de esta unidad es determinar similitudes y diferencias de lingüística y lenguaje mediante el diseño de sistemas computacionales para reconocer fuentes de aplicación del PLN dentro de la Ingeniería en Software.

Temas de la Unidad 3:

- Introducción al PLN
- Conceptos empleados en el PLN
- Lenguaje
- Lingüística
- Gramáticas y expresiones regulares
- Aplicaciones del PLN en Ingeniería en Software

1. Introducción al Procesamiento del Lenguaje Natural (PLN)

1.1 ¿Qué es el PLN?

El Procesamiento del Lenguaje Natural (PLN) es un área de la Inteligencia Artificial que busca desarrollar métodos computacionales capaces de procesar, analizar, interpretar y generar lenguaje utilizado por las personas. Combina conocimientos provenientes de la filosofía del lenguaje, la lingüística, la representación del conocimiento y el razonamiento lógico y probabilístico.

1.2 Ingeniería de Software y PLN

En Ingeniería de Software, el PLN puede entenderse como una tecnología que permite construir sistemas capaces de trabajar con información expresada en lenguaje humano. Algunos ejemplos:

- Analizar requisitos escritos por usuarios.
- Buscar información en grandes volúmenes de documentos.
- Clasificar documentos.
- Extraer información de textos.
- Construir asistentes conversacionales.
- Analizar comentarios y opiniones.
- Detectar determinados patrones en documentos.
- Facilitar la interacción entre personas y sistemas de software.

1.3 Idea fundamental

Un sistema de PLN no debe limitarse a identificar palabras. Debe intentar establecer qué significa una expresión y en qué contexto se utiliza.

Por ejemplo, la frase: "El sistema está caído." Un sistema sencillo puede reconocer las palabras "sistema" y "caído". Un sistema de PLN debe ser capaz de interpretar que, en un contexto informático, probablemente significa que el sistema de software no está funcionando, y no que un objeto físico cayó. Esto es: el significado depende tanto de la expresión como del contexto en el que se produce.

2. Conceptos empleados en el PLN

2.1 Lenguaje natural

Es el lenguaje utilizado espontáneamente por las personas para comunicarse, como español, inglés, francés, alemán, etc. Los lenguajes naturales son altamente expresivos, pero presentan características que dificultan su procesamiento automático: ambigüedad, dependencia del contexto, variaciones lingüísticas, expresiones idiomáticas, conocimiento implícito y diferentes formas de expresar una misma idea.

Russell y Norvig destacan que los lenguajes naturales son muy expresivos y que su significado puede depender del contexto.

2.2 Sintaxis

La sintaxis estudia cómo se organizan las palabras para formar estructuras válidas. Por ejemplo, la oración "El estudiante desarrolla el sistema" puede dividirse en:

- **Frase nominal (FN):** El estudiante
- **Frase verbal (FV):** desarrolla el sistema
- **Sentencia (S):** El estudiante desarrolla el sistema.

Russell y Norvig explican que las gramáticas suelen trabajar con estructuras de frase y utilizan categorías como FN (frase nominal), FV (frase verbal) y S (sentencia).

2.3 Semántica

La semántica se ocupa del significado de las expresiones. Por ejemplo, en la oración "El usuario solicita información", el análisis semántico busca determinar quién realiza la acción, cuál es la acción y sobre qué objeto se realiza.

El libro plantea la interpretación semántica como el proceso de asociar una expresión con una representación de su significado. También presenta el principio de semántica composicional, según el cual el significado de una estructura puede construirse a partir del significado de sus componentes.

2.4 Pragmática

La pragmática considera el significado de una expresión dentro de una situación concreta. Por ejemplo, la frase "Hace frío aquí" dependiendo del contexto puede significar:

- Una simple observación.
- Una petición para cerrar una ventana.
- Una solicitud para encender la calefacción.

Por ello, el PLN debe considerar que el significado no siempre se encuentra literalmente en las palabras. La pragmática estudia precisamente el significado real de una expresión cuando se utiliza en una situación determinada.

2.5 Ambigüedad

La ambigüedad ocurre cuando una expresión puede tener más de una interpretación. Ejemplo: "Cada programador revisó un sistema" puede interpretarse como "cada programador revisó un sistema diferente" o como "todos revisaron el mismo sistema".

Russell y Norvig muestran que incluso una oración aparentemente sencilla puede tener diferentes interpretaciones semánticas debido al alcance de los cuantificadores.

Importancia para Ingeniería de Software: la ambigüedad constituye un problema relevante cuando se intenta convertir requisitos escritos en lenguaje natural en especificaciones formales o código.

3. Lenguaje

El lenguaje puede entenderse como un sistema de signos convencionales utilizados para comunicar información. Está constituido por signos convencionales asociados con significados, y destaca una característica particularmente importante del lenguaje humano: la capacidad de utilizar la gramática para producir una variedad prácticamente ilimitada de mensajes estructurados.

3.1 Lenguaje natural vs. lenguaje formal

Un lenguaje formal posee reglas explícitas para determinar qué cadenas son válidas. Por ejemplo, una expresión aritmética puede establecer reglas que indiquen que si X e Y son expresiones, entonces X + Y también es una expresión.

En cambio, los lenguajes naturales poseen gramáticas que no están completamente formalizadas. Los lingüistas estudian sus propiedades e intentan codificarlas mediante gramáticas, pero esta tarea no se ha conseguido completamente.

Esto explica uno de los grandes retos del PLN: los seres humanos pueden comprender expresiones que una máquina no puede interpretar correctamente sin conocimiento adicional.

4. Lingüística

La lingüística es fundamental para el PLN porque estudia científicamente el lenguaje humano. Russell y Norvig destacan que la lingüística moderna y la Inteligencia Artificial convergieron en un campo híbrido denominado lingüística computacional o procesamiento del lenguaje natural.

Desde una perspectiva computacional podemos identificar diferentes niveles:

- **1. Fonética y fonología:** estudian los sonidos del lenguaje.
- **2. Morfología:** estudia la estructura interna de las palabras. Ejemplo: "programadores" se descompone en "programar + dor + es".
- **3. Sintaxis:** estudia cómo se combinan las palabras.

- **4. Semántica:** estudia el significado.
- **5. Pragmática:** estudia cómo el contexto modifica la interpretación.
- **6. Discurso:** analiza cómo se relacionan varias oraciones dentro de un texto o conversación.

Por ello, el PLN puede verse como un puente entre: Lingüística → Matemáticas → Informática → Inteligencia Artificial → Ingeniería de Software.

5. Gramáticas y expresiones regulares

5.1 ¿Qué es una gramática?

Una gramática es un conjunto de reglas que permite especificar un lenguaje. Russell y Norvig explican que una gramática consiste en un conjunto finito de reglas que especifican un lenguaje. Los lenguajes formales poseen gramáticas explícitas, mientras que las gramáticas de los lenguajes naturales son mucho más complejas.

Una gramática puede utilizar: símbolos terminales, símbolos no terminales, reglas de producción y símbolo inicial. Al aplicar las reglas se puede generar oraciones como "El estudiante desarrolla el sistema", formando un árbol sintáctico.

5.2 Gramáticas independientes del contexto (CFG)

Las gramáticas independientes del contexto (CFG) son particularmente importantes para el análisis sintáctico. Permiten representar la estructura jerárquica de las oraciones mediante reglas de producción.

Russell y Norvig señalan que las gramáticas de estructura de frase y, particularmente, las gramáticas independientes del contexto, constituyen herramientas útiles para trabajar algunos aspectos del lenguaje natural. Sin embargo, una gramática por sí sola no resuelve completamente el problema del PLN, porque el lenguaje también requiere interpretación semántica y conocimiento del contexto.

5.3 Expresiones regulares

Una expresión regular (Regular Expression o RegEx) es un patrón utilizado para identificar determinadas secuencias de caracteres dentro de un texto. Son especialmente útiles cuando se necesita localizar información que tiene una estructura relativamente predecible.

Por ejemplo, para identificar números: [0-9]+ significa "uno o más dígitos". Las expresiones regulares son herramientas para construir sistemas de extracción de información, que permiten definir una gramática regular sobre una secuencia de texto.

Ejemplo: supongamos el texto "El producto cuesta $249.99." Una expresión regular puede buscar el precio. Conceptualmente: $[0-9]+(\.[0-9][0-9])?

Las expresiones regulares pueden utilizarse para:

- Validar correos electrónicos.
- Identificar teléfonos.
- Detectar fechas.

- Extraer códigos.
- Identificar números.
- Localizar identificadores.
- Procesar archivos de texto.
- Limpiar datos.
- Extraer información de documentos.

El libro menciona aplicaciones de expresiones regulares en herramientas como grep, Perl y Microsoft Word, además de su utilización en sistemas de extracción de información.

5.4 Gramáticas vs. expresiones regulares

RegEx busca patrones; una gramática describe estructuras.

6. Aplicaciones del PLN en Ingeniería de Software

6.1 Ingeniería de requisitos

Los requisitos suelen escribirse mediante lenguaje natural, como: "El sistema deberá permitir al administrador generar reportes mensuales." El PLN puede ayudar a: identificar actores, identificar acciones, detectar objetos, extraer restricciones, clasificar requisitos, identificar términos ambiguos, detectar requisitos duplicados y analizar grandes cantidades de documentos.

Ejemplo: Entrada: "El administrador podrá consultar y descargar los reportes de ventas." El sistema podría identificar actores (administrador), acciones (consultar, descargar) y objetos (reportes de ventas). Esto permite apoyar la transformación de lenguaje natural a especificación de software.

6.2 Análisis automático de documentos

En proyectos de software se generan grandes cantidades de documentación como: historias de usuario, requisitos, manuales, tickets, incidencias, casos de prueba, documentación técnica. El PLN puede clasificar y organizar automáticamente estos documentos.

Esto se relaciona con el enfoque basado en corpus descrito por Russell y Norvig, donde grandes colecciones de textos pueden utilizarse para que el software encuentre y procese información relevante.

6.3 Extracción de información

La extracción de información consiste en convertir información encontrada en un texto en datos estructurados. Russell y Norvig describen este proceso como la creación de entradas de una base de datos a partir de información contenida en textos, identificando objetos, acontecimientos y relaciones.

Ejemplo aplicado a software: Texto: "La aplicación presentó 15 errores críticos durante septiembre." Podemos extraer: Sistema = aplicación, Cantidad = 15, Tipo = errores, Severidad = crítica, Periodo = septiembre. Esto permite integrar PLN con bases de datos, analítica y sistemas de gestión de software.

6.4 Gestión de incidencias

En plataformas de soporte técnico, los usuarios escriben cosas como: "No puedo iniciar sesión desde ayer." El PLN puede clasificar automáticamente la incidencia como: Categoría: Autenticación, Prioridad: Alta, Problema: Inicio de sesión, Tiempo: Desde ayer. Esto permite automatizar parcialmente la clasificación de tickets.

6.5 Chatbots y asistentes virtuales

Los asistentes conversacionales utilizan PLN para: recibir lenguaje humano, identificar la intención, extraer información relevante, consultar una base de conocimiento y generar una respuesta. El libro considera la comunicación entre agentes humanos y software y destaca que para obtener el significado completo de una expresión son necesarios análisis sintácticos y semánticos.

6.6 Búsqueda de información

El PLN permite mejorar los sistemas de búsqueda porque el sistema puede trabajar no solamente con coincidencias exactas, sino con conceptos y relaciones entre términos. Por ejemplo, la búsqueda "problemas para acceder al sistema" puede relacionarse con error de autenticación, contraseña incorrecta, acceso denegado o usuario bloqueado.

Esto es especialmente importante en sistemas de soporte, repositorios de conocimiento, documentación técnica, bases de datos y buscadores empresariales.

6.7 Análisis de código y documentación

En Ingeniería de Software también es posible utilizar PLN para analizar: comentarios del código, nombres de variables, documentación, commits, reportes de errores, historias de usuario. Por ejemplo, un sistema podría analizar el comentario "// corregir error de autenticación cuando la sesión expira" y clasificarlo como una tarea relacionada con seguridad/autenticación.

6.8 Generación automática de documentación

Otra aplicación consiste en transformar información técnica estructurada en lenguaje comprensible. Por ejemplo, dada la función registrar_usuario() con los parámetros nombre, correo y contraseña, el sistema puede generar la descripción: "La función registrar_usuario permite crear una nueva cuenta utilizando el nombre, correo electrónico y contraseña proporcionados." Esto vincula PLN con herramientas de documentación automática y mantenimiento de software.

6.9 Pruebas de software

Un área particularmente interesante es utilizar PLN para transformar requisitos en posibles casos de prueba. Dado el requisito: "El sistema deberá bloquear la cuenta después de tres intentos incorrectos", el PLN puede ayudar a identificar: Condición: 3 intentos incorrectos, Resultado esperado: cuenta bloqueada. Aquí observamos una integración de PLN + Ingeniería de Requisitos + Pruebas de Software.

7. Integración conceptual: ¿Cómo entiende una computadora el lenguaje?

Las computadoras no comprenden el lenguaje como lo hacen las personas. Para ellas, un documento es simplemente una secuencia de símbolos que debe transformarse en representaciones numéricas antes de poder analizarlo. De

manera simplificada, el proceso ocurre en varias etapas, utilizando bibliotecas especializadas en Python como spaCy, NLTK, Transformers de Hugging Face, entre otras.

8. Conclusión

El Procesamiento del Lenguaje Natural representa un punto de encuentro entre la Inteligencia Artificial, la lingüística y la computación. Donde el problema es mucho más complejo que identificar palabras o estructuras: la comprensión requiere considerar sintaxis, semántica, ambigüedad, conocimiento y contexto.

Para la Ingeniería de Software, el PLN tiene especial valor porque permite transformar información expresada en lenguaje humano en estructuras que pueden ser procesadas computacionalmente. Las gramáticas permiten representar estructuras lingüísticas, mientras que las expresiones regulares permiten localizar patrones específicos dentro de textos.

El PLN no consiste solamente en hacer que una computadora "lea" texto; consiste en desarrollar mecanismos para que un sistema pueda extraer estructura, significado e información útil del lenguaje humano y utilizarla en procesos de software.

Esto abre aplicaciones en ingeniería de requisitos, extracción de información, gestión de incidencias, búsqueda inteligente, documentación automática, asistentes virtuales y generación de casos de prueba.

Fuente base: Russell, S. J., & Norvig, P. Inteligencia Artificial: Un Enfoque Moderno, 2.ª edición, editorial Pearson Educación.