Unidad 3
Procesamiento del lenguaje natural- PLN

Determinar similitudes y diferencias de liguistica y lenguaje mediante el diseño de sistemas computacionales para reconocer fuentes de aplicación del PLN dentro de la ingeniería en software.

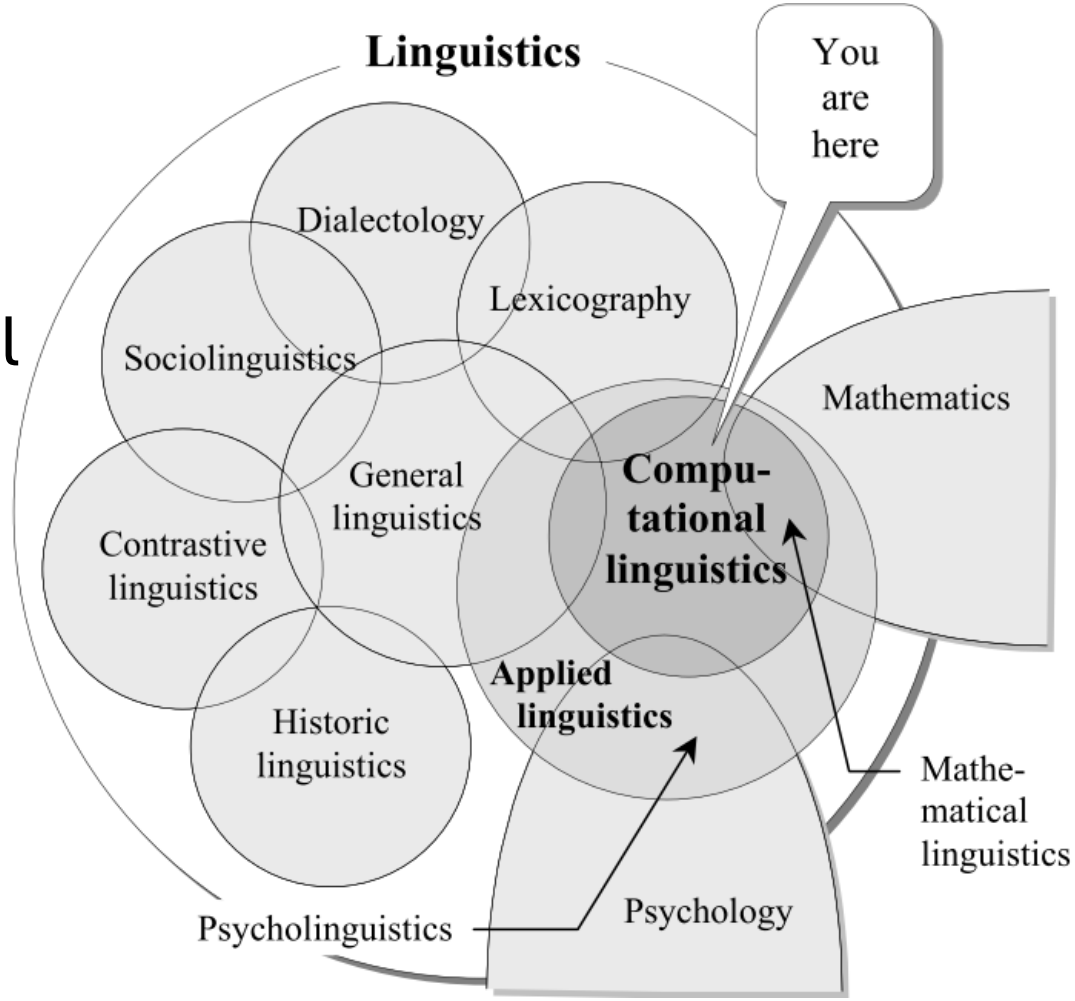
Temas

1. Introducción al PLN
   - Conceptos empleados en el PLN
   - Lenguaje
   - Lingüística
2. Gramáticas y expresiones regulares
3. Aplicaciones del PLN en Ingeniería en software

Introducción al Procesamiento del Lenguaje Natural (PLN)

¿Qué es el PLN?

- El **Procesamiento del Lenguaje Natural (PLN)** es un área de la Inteligencia Artificial que busca desarrollar métodos computacionales capaces de **procesar, analizar, interpretar y generar lenguaje utilizado por las personas**. Este además, combina conocimientos provenientes de la **filosofía del lenguaje, la lingüística, la representación del conocimiento y el razonamiento lógico y probabilístico**.



Ingeniería de Software y PLN

En Ingeniería de Software, el PLN puede entenderse como una tecnología que permite construir sistemas capaces de trabajar con información expresada en lenguaje humano, por ejemplo:

- Analizar requisitos escritos por usuarios.
- Buscar información en grandes volúmenes de documentos.
- Clasificar documentos.
- Extraer información de textos.
- Construir asistentes conversacionales.
- Analizar comentarios y opiniones.
- Detectar determinados patrones en documentos.
- Facilitar la interacción entre personas y sistemas de software.

Ingeniería de Software y PLN

Idea fundamental

- Un sistema de PLN no debe limitarse a identificar palabras. Debe intentar establecer **qué significa una expresión y en qué contexto se utiliza**.

Por ejemplo: "El sistema está caído."

- Un sistema sencillo puede reconocer las palabras *sistema* y *caído*. Un sistema de PLN debe ser capaz de interpretar que, en un contexto informático, probablemente significa que **el sistema de software no está funcionando**, y no que un objeto físico cayó.
- Esto es, el significado depende tanto de la expresión como del **contexto** en el que se produce.

Conceptos empleados en el PLN

Lenguaje natural

- Es el lenguaje utilizado espontáneamente por las personas para comunicarse, como español, inglés, francés, alemán, etc.
- Los lenguajes naturales son altamente expresivos, pero presentan características que dificultan su procesamiento automático: ambigüedad, dependencia del contexto, variaciones lingüísticas, expresiones idiomáticas, conocimiento implícito, diferentes formas de expresar una misma idea.
- Russell y Norvig destacan que los lenguajes naturales son muy expresivos y que su significado puede depender del contexto.

Conceptos empleados en el PLN

Sintaxis

- La **sintaxis** estudia cómo se organizan las palabras para formar estructuras válidas.

Por ejemplo: El estudiante desarrolla el Sistema.

La oración puede dividirse en:

  - **Frase nominal (FN):** El estudiante
  - **Frase verbal (FV):** desarrolla el sistema
  - **Sentencia (S):** El estudiante desarrolla el sistema.

- Russell y Norvig explican que las gramáticas suelen trabajar con estructuras de frase y utilizan categorías como **FN (frase nominal), FV (frase verbal) y S (sentencia)**.

Conceptos empleados en el PLN

Semántica

- La **semántica** se ocupa del significado de las expresiones.

Por ejemplo: El usuario solicita información.

El análisis semántico busca determinar:

- quién realiza la acción
- cuál es la acción;
- sobre qué objeto se realiza

- El libro plantea la interpretación semántica como el proceso de asociar una expresión con una representación de su significado. También presenta el principio de **semántica composicional**, según el cual el significado de una estructura puede construirse a partir del significado de sus componentes.

Conceptos empleados en el PLN

Pragmática

- La **pragmática** considera el significado de una expresión dentro de una situación concreta.

Por ejemplo: Hace frío aquí.

Dependiendo del contexto, puede significar:

- una simple observación
- una petición para cerrar una ventana
- una solicitud para encender la calefacción

- Por ello, el PLN debe considerar que **el significado no siempre se encuentra literalmente en las palabras**. El libro señala que la pragmática estudia precisamente el significado real de una expresión cuando se utiliza en una situación determinada.

Conceptos empleados en el PLN

Ambigüedad

- La ambigüedad ocurre cuando una expresión puede tener más de una interpretación.

Ejemplo: Cada programador revisó un sistema.

Puede interpretarse como:

  - cada programador revisó un sistema diferente;
  - todos revisaron el mismo sistema.

- Russell y Norvig muestran que incluso una oración aparentemente sencilla puede tener diferentes interpretaciones semánticas debido al alcance de los cuantificadores.
- **Importancia para Ingeniería de Software:**
  La ambigüedad constituye un problema relevante cuando se intenta convertir requisitos escritos en lenguaje natural en especificaciones formales o código.

Lenguaje

- El lenguaje puede entenderse como un **sistema de signos convencionales utilizados para comunicar información**.
- El lenguaje está constituido por signos convencionales asociados con significados y destacan una característica particularmente importante del lenguaje humano: la capacidad de utilizar la gramática para producir una variedad prácticamente ilimitada de mensajes estructurados.

Desde la perspectiva de la Ingeniería de Software, podemos establecer una comparación:

Lenguaje natural	**Lenguaje de programación**
Español	Python
Inglés	Java
Tiene ambigüedad	Busca evitar ambigüedad
Depende del contexto	Tiene reglas formales
Evoluciona socialmente	Es diseñado formalmente
Puede ser impreciso	Busca precisión sintáctica y semántica
Tiene múltiples interpretaciones	Debe tener una interpretación computacional definida

Lenguajes

Lenguaje natural vs. lenguaje formal

- Un **lenguaje formal** posee reglas explícitas para determinar qué cadenas son válidas.
- Por ejemplo, una expresión aritmética puede establecer reglas que indiquen que si X e Y son expresiones, entonces X + Y también es una expresión.
- En cambio, los lenguajes naturales poseen gramáticas que no están completamente formalizadas. Los lingüistas estudian sus propiedades e intentan codificarlas mediante gramáticas, pero esta tarea no se ha conseguido completamente.

Esto explica uno de los grandes retos del PLN:

> Los seres humanos pueden comprender expresiones que una máquina no puede interpretar correctamente sin conocimiento adicional.

Lingüística

- La **lingüística** es fundamental para el PLN porque estudia científicamente el lenguaje humano.
- Russell y Norvig destacan que la lingüística moderna y la Inteligencia Artificial convergieron en un campo híbrido denominado **lingüística computacional o procesamiento del lenguaje natural**.

Desde una perspectiva computacional podemos identificar diferentes niveles:

1. **Fonética y fonología :**Estudian los sonidos del lenguaje.
2. **Morfología:** Estudia la estructura interna de las palabras.

   Ejemplo: programadores → programar + dor + es

Lingüística

- **3. Sintaxis:** Estudia cómo se combinan las palabras.
- **4. Semántica:** Estudia el significado.
- **5. Pragmática:** Estudia cómo el contexto modifica la interpretación.
- **6. Discurso:** Analiza cómo se relacionan varias oraciones dentro de un texto o conversación.

Por ello, el PLN puede verse como un puente entre:

- **Lingüística → Matemáticas → Informática → Inteligencia Artificial → Ingeniería de Software**

Gramáticas

¿Qué es una gramática? Es un conjunto de reglas que permite especificar un lenguaje.

- Russell y Norvig explican que una gramática consiste en un conjunto finito de reglas que especifican un lenguaje. Los lenguajes formales poseen gramáticas explícitas, mientras que las gramáticas de los lenguajes naturales son mucho más complejas.
- Una gramática puede utilizar: símbolos terminales, símbolos no terminales, reglas de producción y símbolo inicial.

Por ejemplo:

```
S  → FN FV
FN → Artículo Nombre
FV → Verbo FN
```

Podemos generar:

El estudiante desarrolla el sistema.

La estructura sería:

```
S
├── FN
│   ├── Artículo: El
│   └── Nombre: estudiante
│
└── FV
    ├── Verbo: desarrolla
    └── FN
        ├── Artículo: el
        └── Nombre: sistema
```

Esto constituye un **árbol sintáctico**.

Gramáticas independientes del contexto

Las **gramáticas independientes del contexto (CFG)** son particularmente importantes para el análisis sintáctico.

- Permiten representar estructuras mediante reglas como:

```
S → FN FV
FN → Artículo Nombre
FV → Verbo FN
```

- Una ventaja importante es que permiten representar la estructura jerárquica de las oraciones.
- Russell y Norvig señalan que las gramáticas de estructura de frase y, particularmente, las gramáticas independientes del contexto, constituyen herramientas útiles para trabajar algunos aspectos del lenguaje natural.
- Sin embargo, **una gramática por sí sola no resuelve completamente el problema del PLN**, porque el lenguaje también requiere interpretación semántica y conocimiento del contexto.

Expresiones regulares

Una **expresión regular (Regular Expression o RegEx)** es un patrón utilizado para identificar determinadas secuencias de caracteres dentro de un texto. Son especialmente útiles cuando se necesita localizar información que tiene una estructura relativamente predecible.

Por ejemplo, para identificar números:

[0-9]+ significa: uno o más dígitos.

Las expresiones regulares son herramientas para construir sistemas de extracción de información, que permiten definir una gramática regular sobre una secuencia de texto.

Ejemplo

- Supongamos el texto: El producto cuesta $249.99.

Una expresión regular puede buscar el precio.

Conceptualmente: $[0-9]+(\.[0-9][0-9])?

Componentes básicos de una expresión regular

Las expresiones regulares pueden utilizarse para:

- Validar correos electrónicos
- Identificar teléfonos
- Detectar fechas
- Extraer códigos
- Identificar números
- Localizar identificadores
- Procesar archivos de texto
- Limpiar datos
- Extraer información de documentos

El libro menciona aplicaciones de expresiones regulares en herramientas como **grep, Perl y Microsoft Word**, además de su utilización en sistemas de extracción de información.

Elemento	Función	Ejemplo
[0-9]	Un dígito	5
[0-9]+	Uno o más dígitos	250
?	Elemento opcional	250.99 o 250
.	Separador decimal	.
()	Agrupación	(abc)
*	Cero o más repeticiones	a*
+	Una o más repeticiones	a+

Gramáticas vs. expresiones regulares

RegEx busca patrones
una gramática describe estructuras.

Característica	Expresión regular	Gramática
Complejidad	Baja-media	Media-alta
Objetivo	Encontrar patrones	Representar estructura
Trabaja principalmente con	Cadenas	Estructuras lingüísticas
Contexto	Limitado	Puede representar estructuras jerárquicas
Ejemplo	Encontrar un correo	Analizar una oración
Aplicación	Validación/extracción	Análisis sintáctico

Aplicaciones del PLN (APLN) en Ingeniería de Software

Ingeniería de requisitos : Los requisitos suelen escribirse mediante lenguaje natural:
"El sistema deberá permitir al administrador generar reportes mensuales.“

El PLN puede ayudar a:

- Identificar actores
- Identificar acciones
- Detectar objetos
- Extraer restricciones
- Clasificar requisitos
- Identificar términos ambiguos
- Detectar requisitos duplicados
- Analizar grandes cantidades de documentos

Elemento	**Resultado**
Actor	Administrador
Acción	Consultar
Acción	Descargar
Objeto	Reportes
Dominio	Ventas

Ejemplo
Entrada: "El administrador podrá consultar y descargar los reportes de ventas.“

El sistema podría identificar:
Esto permite apoyar la transformación de **lenguaje natural → especificación de software**

APLN-Análisis automático de documentos

En proyectos de software se generan grandes cantidades de documentación como: historias de usuario, requisites, manuals, tickets, incidencias, casos de prueba, documentación técnica.

El PLN puede clasificar y organizar automáticamente estos documentos.

Esto se relaciona con el enfoque basado en **corpus** descrito por Russell y Norvig, donde grandes colecciones de textos pueden utilizarse para que el software encuentre y procese información relevante.

APLN-Extracción de información

La **extracción de información** consiste en convertir información encontrada en un texto en datos estructurados.
Russell y Norvig describen este proceso como la creación de entradas de una base de datos a partir de información contenida en textos, identificando objetos, acontecimientos y relaciones.

Ejemplo aplicado a software

Texto: "La aplicación presentó 15 errores críticos durante septiembre."

Podemos extraer:

Sistema = aplicación
Cantidad = 15
Tipo = errores
Severidad = crítica
Periodo = septiembre

Y almacenarlo en: Esto permite integrar PLN con **bases de datos, analítica y sistemas de gestión de software**.

Sistema	Errores	Severidad	Periodo
Aplicación	15	Crítica	Septiembre

APLN-Gestión de incidencias

En plataformas de soporte técnico, los usuarios escriben:

"No puedo iniciar sesión desde ayer."

El PLN puede clasificar automáticamente la incidencia como:

Categoría: Autenticación
Prioridad: Alta
Problema: Inicio de sesión
Tiempo: Desde ayer

Esto permite automatizar parcialmente la clasificación de tickets.

APLN-Chatbots y asistentes virtuales

- Los asistentes conversacionales utilizan PLN para: recibir lenguaje humano, identificar la intención, extraer información relevante, consultar una base de conocimiento y generar una respuesta.
- El libro considera la comunicación entre agentes humanos y software y destaca que para obtener el significado completo de una expresión son necesarios análisis sintácticos y semánticos.

APLN-Búsqueda de información

El PLN permite mejorar los sistemas de búsqueda porque el sistema puede trabajar no solamente con coincidencias exactas, sino con conceptos y relaciones entre términos.

Por ejemplo: "problemas para acceder al sistema"

puede relacionarse con error de autenticación, contraseña incorrecta, acceso denegado o usuario bloqueado.

Esto es especialmente importante en sistemas de soporte, repositorios de conocimiento, documentación técnica, bases de datos y buscadores empresariales.

APLN-Análisis de código y documentación

En Ingeniería de Software también es posible utilizar PLN para analizar: comentarios del código, nombres de variables, documentación, commits, reportes de errores, historias de usuario.

Por ejemplo, un sistema podría analizar:

// corregir error de autenticación cuando la sesión expira

y clasificarlo como una tarea relacionada con seguridad/autenticación.

APLN-Generación automática de documentación

Otra aplicación consiste en transformar información técnica estructurada en lenguaje comprensible.

Por ejemplo: Función: registrar_usuario()

Parámetros: nombre, correo y contraseña

El sistema puede generar una descripción:

> "La función registrar_usuario permite crear una nueva cuenta utilizando el nombre, correo electrónico y contraseña proporcionados."

Esto vincula PLN con herramientas de documentación automática y mantenimiento de software.

APLN-Pruebas de software

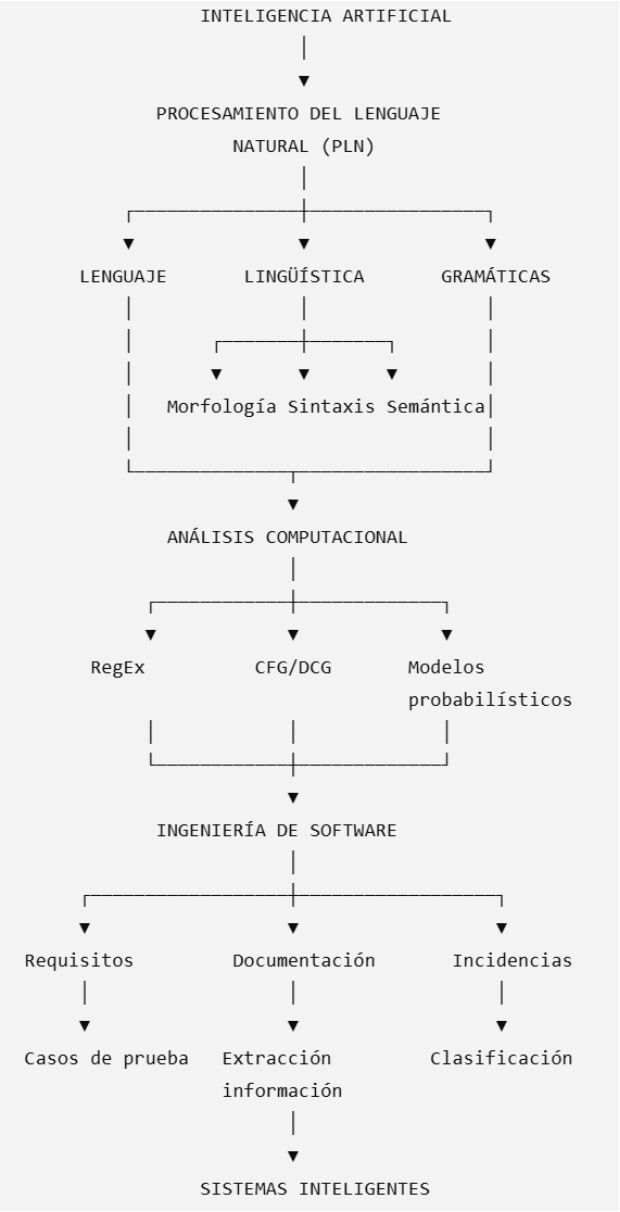
Un área particularmente interesante es utilizar PLN para transformar requisitos en posibles casos de prueba.
Requisito: "El sistema deberá bloquear la cuenta después de tres intentos incorrectos."
El PLN puede ayudar a identificar:

- Condición: 3 intentos incorrectos
- Resultado esperado: cuenta bloqueada

Generando escenarios: Aquí observamos una integración de **PLN + Ingeniería de Requisitos + Pruebas de Software**

Caso	Entrada	Resultado esperado
1	1 intento incorrecto	Cuenta activa
2	2 intentos incorrectos	Cuenta activa
3	3 intentos incorrectos	Cuenta bloqueada

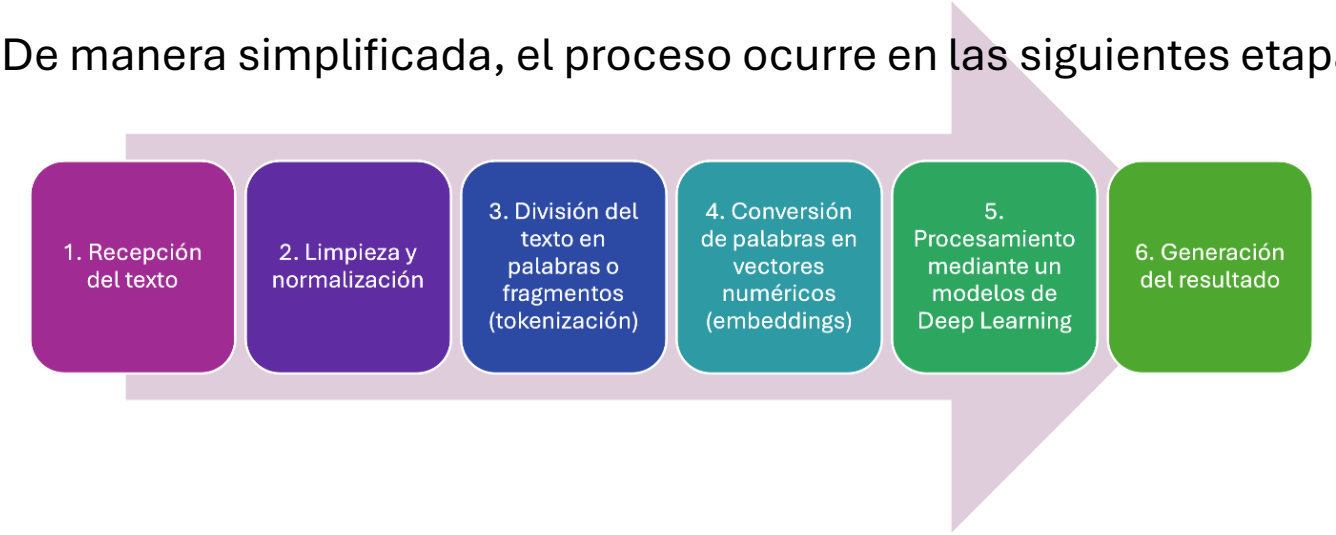
Integración conceptual



¿Cómo entiende una computadora el lenguaje?

Las computadoras no comprenden el lenguaje como lo hacen las personas. Para ellas, un documento es simplemente una secuencia de símbolos que debe transformarse en representaciones numéricas antes de poder analizarlo.

De manera simplificada, el proceso ocurre en las siguientes etapas:



Bibliotecas especializadas en Python

Herramienta	Aplicación principal
NLTK	Enseñanza y procesamiento clásico
spaCy	Procesamiento eficiente de textos
Gensim	Modelado de temas y Word Embeddings
Hugging Face Transformers	Modelos modernos de Deep Learning
TensorFlow	Desarrollo de modelos neuronales
PyTorch	Investigación en Deep Learning
Scikit-learn	Clasificación y minería de textos

APLICACIONES DEL PROCESAMIENTO DEL LENGUAJE NATURAL

El PLN permite a las computadoras comprender, analizar y generar lenguaje humano para transformar texto en información útil.



1 CLASIFICACIÓN DE DOCUMENTOS

Organizar automáticamente artículos, tesis o documentos administrativos según su temática.



Resultado: Documentos clasificados y organizados por categoría.

2 ANÁLISIS DE SENTIMIENTOS

Determinar si un texto expresa opiniones positivas, negativas o neutrales.



Resultado: Detección automática de la **polaridad del sentimiento.**

3 TRADUCCIÓN AUTOMÁTICA

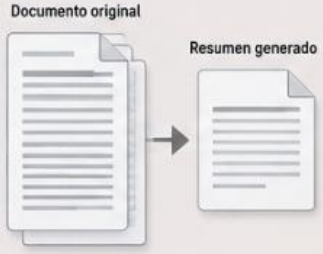
Convertir texto de un idioma a otro.



Resultado: Traducción rápida y precisa entre idiomas.

4 RESUMEN AUTOMÁTICO

Generar versiones resumidas de documentos extensos.



Resultado: Resúmenes claros que conservan las ideas principales.

5 EXTRACCIÓN DE INFORMACIÓN

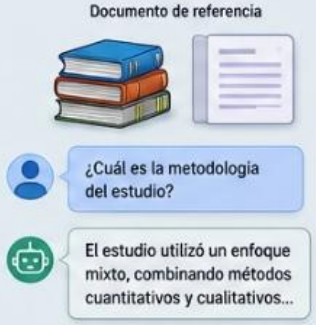
Identificar automáticamente personas, instituciones, lugares, fechas y conceptos relevantes.



Resultado: Información estructurada extraída del texto.

6 SISTEMAS DE PREGUNTAS Y RESPUESTAS

Responder preguntas utilizando documentos de referencia.



Resultado: Respuestas precisas basadas en la información disponible.

7 GENERACIÓN AUTOMÁTICA DE TEXTO

Crear contenido nuevo manteniendo coherencia y contexto.



Resultado: Contenido coherente, relevante y bien estructurado.

El Procesamiento del Lenguaje Natural transforma grandes volúmenes de texto en conocimiento útil, impulsando la investigación, la educación y la toma de decisiones.

EL FUTURO DEL PROCESAMIENTO DE LENGUAJE NATURAL

Impulsado por los Modelos Grandes de Lenguaje (LLM)

El desarrollo reciente de los Modelos Grandes de Lenguaje (Large Language Models, LLM) ha ampliado significativamente las capacidades del PLN.



CAPACIDADES ACTUALES DE LOS LLM

Comprender instrucciones complejas

Entienden solicitudes detalladas y con múltiples pasos.

Ejemplo:
"Analiza este artículo, extrae los hallazgos principales y compara con estudios previos."

Generar texto coherente

Producen contenido fluido, relevante y con contexto.

Ejemplo:
"Redacta una introducción para un artículo sobre inteligencia artificial en la educación."

Resumir documentos

Extraen las ideas más importantes de textos extensos.

Ejemplo:
"Resume este documento en 5 puntos clave."

Traducir idiomas

Realizan traducciones precisas entre múltiples idiomas.

Ejemplo:
"Traduce este texto del español al inglés."

Producir código

Generan código funcional en diferentes lenguajes de programación.

Ejemplo:
"Escribe una función en Python para limpiar y analizar un conjunto de datos."

Responder preguntas con contexto especializado

Responden preguntas utilizando información específica y confiable.

Ejemplo:
"Según este documento, ¿cuáles son las ventajas del aprendizaje profundo?"

IMPACTO EN DISTINTOS ÁMBITOS

Educación
Tutores inteligentes, creación de materiales, apoyo personalizado al aprendizaje.

Investigación
Revisión de literatura, generación de hipótesis, análisis de datos textuales.

Salud
Análisis de historiales clínicos, apoyo en diagnósticos y documentación médica.

Industria y negocios
Atención al cliente automatizada, análisis de opiniones, generación de reportes e insights.



Más inteligentes • Más útiles • Más accesibles

TENDENCIAS QUE DEFINEN EL FUTURO

Modelos más grandes y eficientes
Más parámetros, mejor entrenamiento y menor consumo de recursos.

Mayor confiabilidad y seguridad
Reducción de sesgos, verificación de información y uso ético.

Multimodalidad
Comprender y generar texto, imágenes, audio y video de forma integrada.

Democratización del PLN
Herramientas más accesibles para investigadores, docentes y estudiantes.

EL FUTURO DEL PLN ES PROMETEDOR

Los Modelos Grandes de Lenguaje están transformando la forma en que interactuamos con la información. Continuarán evolucionando para ser más precisos, responsables y adaptados a las necesidades de la sociedad, abriendo nuevas oportunidades para la ciencia, la educación y la innovación.

Conclusión

- El **Procesamiento del Lenguaje Natural** representa un punto de encuentro entre la **Inteligencia Artificial, la lingüística y la computación**. Donde el problema es mucho más complejo que identificar palabras o estructuras: la comprensión requiere considerar **sintaxis, semántica, ambigüedad, conocimiento y contexto**.
- Para la **Ingeniería de Software**, el PLN tiene especial valor porque permite transformar información expresada en lenguaje humano en estructuras que pueden ser procesadas computacionalmente. Las **gramáticas** permiten representar estructuras lingüísticas, mientras que las **expresiones regulares** permiten localizar patrones específicos dentro de textos.
- El PLN no consiste solamente en hacer que una computadora "lea" texto; consiste en desarrollar mecanismos para que un sistema pueda extraer estructura, significado e información útil del lenguaje humano y utilizarla en procesos de software.
- Esto abre aplicaciones en ingeniería de requisitos, extracción de información, gestión de incidencias, búsqueda inteligente, documentación automática, asistentes virtuales y generación de casos de prueba.
- **Fuente base:** Russell, S. J., & Norvig, P. *Inteligencia Artificial: Un Enfoque Moderno*, 2.ª edición, editorial Pearson Educación.